

เข้าใจการวัดผลโมเดล Verification แบบลึก

เขียนสำหรับคนที่อยากเข้าใจ **concept** จริง ๆ ไม่ใช่แค่ท่องสูตร ตัวอย่างทั้งหมดมาจากโมเดล V4 ของคุณจริง พร้อมวิเคราะห์ตรงไปตรงมาว่าอะไรดี/ไม่ดี

สารบัญ

1. [บทนำ — สัมทุกอย่างที่อ่านมาก่อน](#)
2. [Concept ที่สำคัญที่สุด — ทุกอย่างคือเรื่องของ 2 กลุ่มตัวเลข](#)
3. [โมเดลในอุดมคติ vs โมเดลห่วย — เห็นภาพ](#)
4. [Threshold คืออะไรกันแน่ — มันไม่ใช่ความสามารถของโมเดล](#)
5. [4 ผลลัพธ์ที่เป็นไปได้ — เข้าใจ Confusion Matrix แบบลึก](#)
6. [เมตริกแต่ละตัว — มันมีไว้ทำไม](#)
7. [กราฟ ROC — เข้าใจอย่างผู้เชี่ยวชาญ](#)
8. [กราฟ DET, PR — เมื่อ ROC ไม่พอ](#)
9. [วิเคราะห์ V4 ของคุณตรง ๆ — ดีจริงหรือเปล่า](#)
10. [Red Flags — สัญญาณอันตรายที่ต้องดู](#)
11. [สรุปคำแนะนำจากผู้เชี่ยวชาญ](#)

1. ลืมทุกอย่าง

ก่อนเริ่ม ขอให้คุณ **ลืม** ความคิดเหล่านี้ทิ้งไป:

- ❌ "โมเดลทำนายว่าใช่หรือไม่ใช่"
- ❌ "โมเดลดี = Accuracy สูง"
- ❌ "Threshold 0.5 คือมาตรฐาน"

ทำไม? เพราะเข้าใจแบบนี้ทำให้คุณ **อ่านกราฟไม่เป็น** และตัดสินใจผิด

สิ่งที่ต้องเข้าใจใหม่:

โมเดลของคุณ **ไม่ได้ทำนาย** — มันแค่ **ให้คะแนนความเหมือน** การตัดสินใจว่า "ใช่/ไม่ใช่" เป็นหน้าที่ของ **คน (คุณ)**
ไม่ใช่โมเดล คุณเป็นคนตั้ง threshold = คุณเป็นคนตัดสินใจ

นี่คือ mindset ที่ต้องเปลี่ยน

2. สอง Distributions


หัวใจสำคัญที่สุดของบทนี้

เวลาคุณรัน test set โมเดลคืน "score" มา 4000 ค่า ตอนนี้แยกออกเป็น **2 กลุ่ม**:

กลุ่มที่ 1: คู่ที่เป็นนิ้วเดียวกันจริง (Genuine) – 2024 ค่า
กลุ่มที่ 2: คู่ที่คนละนิ้ว (Impostor) – 1976 ค่า

แต่ละกลุ่มเป็น **distribution** (การกระจายตัวของตัวเลข) เอามาวาดเป็นกราฟแท่งได้

ภาพในใจที่ต้องมี



คำถามเดียวที่ทุก metric พยายามตอบ:

"2 distributions นี้แยกออกจากกันได้ดีแค่ไหน?"

- **แยกออกขาด** → โมเดลในอุดมคติ ($AUC = 1$, $EER = 0\%$)
- **เหลื่อมกันเยอะ** → โมเดลห่วย
- **เหลื่อมกันนิดเดียว** → โมเดลดี


Accuracy, F1, AUC, EER, d-prime, ROC, DET, PR — ทุกตัวคือคำตอบของคำถามเดียวกัน เพียงแต่มองจากมุมต่างกัน

นี่คือ insight สำคัญที่สุด ถ้าจำได้แค่นี้ คุณเข้าใจการวัดผลโมเดล verification 80% แล้ว

3. ภาพในใจ


ก่อนจะพูดถึงเลข ขอให้คุณดู 4 ภาพนี้และจำให้ติดตา:

ภาพ A: โมเดลในอุดมคติ (Perfect)



- แยกขาด **100%** — ไม่มี overlap เลย
- ตั้ง threshold ที่ไหนก็ได้ตรงกลาง → Accuracy 100%
- $AUC = 1.0000$, $EER = 0\%$
- **ไม่มีในชีวิตจริง** — ถ้าได้เลขแบบนี้ ให้สงสัย data leakage ก่อน

ภาพ B: โมเดลดี (Realistic Good)



- เหลื่อมกันนิดหน่อย
- $AUC = 0.99+$, $EER \sim 1-5\%$
- เป้าหมายของระบบ **biometric** ในชีวิตจริง

ภาพ C: โมเดลปานกลาง




- AUC $\sim 0.8-0.9$, EER $\sim 10-20\%$
- ใช้งานได้ดีแต่มีปัญหา

ภาพ D: โมเดลห่วย (เกือบสุ่ม)



- AUC $\sim 0.5-0.7$
- ไม่ควรเอามาใช้

🚨 ภาพ E: โมเดล "ดูดี" แต่จริง ๆ มีปัญหา (Bimodal สุดขั้ว)



นี่คือสิ่งที่ต้องระวัง — โมเดลของคุณตกอยู่ในกลุ่มนี้ (จะอธิบายในข้อ 9-10)

- เลขดูเหมือนดี (AUC สูง) แต่...
- โมเดล **มั่นใจเกินไป** ตอบ 0 หรือ 1 ดิบ ๆ
- ไม่บอก "ความไม่แน่ใจ" — ทำให้คู่ที่ "เกือบจะใช่" ถูกตอบว่า "ไม่ใช่" สนิท
- ทำให้ threshold tuning **ใช้ไม่ได้จริง** เพราะไม่มีค่ากลาง

4. Threshold แท้จริง

Threshold $\neq$ ความสามารถของโมเดล

อันนี้คนเข้าใจผิดเยอะที่สุด

สิ่งที่ **threshold** ทำได้: - เลือกว่าจะรับความเสี่ยงแบบไหน — รับคนแปลกหน้าผ่าน หรือปฏิเสธเจ้าของจริง

สิ่งที่ **threshold** ทำไม่ได้: - ทำให้โมเดลเก่งขึ้น - ลดทั้ง FAR และ FRR พร้อมกัน

Analogy: Threshold คือ "เกณฑ์การคัดคน"

นึกภาพคุณเป็น HR คัดคนเข้าทำงาน — โมเดลให้คะแนนผู้สมัครจาก 0-100

- **Threshold สูง (เช่น 90)** → รับคนน้อย ได้คนเก่งแน่ ๆ แต่พลาดคนดีหลายคน
- **Threshold ต่ำ (เช่น 50)** → รับคนเยอะ ไม่พลาดคนดี แต่ได้คนไม่เก่งปนมา

โมเดลไม่ได้เปลี่ยน — แค่ "นโยบาย" เปลี่ยน

ในงานลายนิ้วมือก็เหมือนกัน: - Threshold สูง = ระบบเข้มงวด = FAR ต่ำ แต่ FRR สูง (ATM, ตม.) - Threshold ต่ำ = ระบบสะดวก = FRR ต่ำ แต่ FAR สูง (เปิดประตู office)

Insight สำคัญ: ความสามารถของโมเดลคือ "ระยะห่างของ 2 distributions"

ไม่ใช่ "ตัวเลข accuracy ที่ threshold ใดๆ"

วิธีวัดความสามารถจริง = **AUC** หรือ **d-prime** หรือ **EER** — เพราะ 3 ตัวนี้ไม่ขึ้นกับ threshold

5. Confusion Matrix ลึก

มันบอกอะไรจริง ๆ

Confusion Matrix ไม่ใช่ "เครื่องวัดโมเดล" — มันคือ **snapshot ของผลลัพธ์ ณ threshold หนึ่ง**

ถ้าคุณเปลี่ยน threshold ตารางก็เปลี่ยน — เพราะฉะนั้น Confusion Matrix เดียวเท่ากับว่า **คุณเลือกใช้นโยบายหนึ่ง แล้ว**
โซ่ผลของนโยบายนั้น

4 ช่องตาราง = 4 เรื่องราว

	ทำนาย ไม่ใช่	ทำนาย ใช่	
จริง: ไม่ใช่ (impostor)	TN "กรองได้!"	FP "หลุดเข้า!"	← เรื่อง security
จริง: ใช่ (genuine)	FN "ปฏิเสธ เจ้าของ"	TP "เจอ เจ้าของ!"	← เรื่อง usability

ทั้ง 4 ช่องมีความหมายเชิงธุรกิจต่างกัน:

ช่อง	ผลกระทบจริง
TP สูง = ดี	ระบบทำงาน เจ้าของผ่านได้
TN สูง = ดี	กรองคนแปลกหน้าได้
FP สูง = อันตราย	คนแปลกหน้าผ่านได้ — security breach
FN สูง = น่ารำคาญ	เจ้าของถูกปฏิเสธ — ลูกค้าโกรธ

คำถามเชิงกลยุทธ์: FP กับ FN แบบไหนแยกว่ากัน

ขึ้นกับ use case 100%

Use case	FP แย่	FN แย่
ATM, ตม., กองทัพ	★★★★★	★★
ปลดล็อคมือถือ	★★★	★★★★
เข้า office	★	★★★★★

→ **คุณต้องตอบให้ได้ก่อน** ว่าระบบของคุณเอาไปใช้ที่ไหน แล้วถึงเลือก threshold

ตัวอย่าง V4 ของคุณ (threshold 0.70)

	ทำนาย ไม่ใช่	ทำนาย ใช่	
ไม่ใช่	TN = 1974	FP = 2	→ กรอง impostor ได้ 99.9%
ใช่	FN = 367	TP = 1657	→ จับ genuine ได้แค่ 82%

สิ่งที่ตารางนี้บอก: - โมเดล **อนุรักษ์นิยม (conservative)** สุดขีด — กรอง impostor เกือบสมบูรณ์ - แต่ก็ **ปฏิเสธเจ้าของจริงเยอะ** — $367/2024 = 18\%$ นี่เยอะมาก - ถ้าระบบนี้คือมือถือ → ผู้ใช้ต้องสแกน **5 ครั้งโดยเฉลี่ย** ก่อนจะปลดล็อคได้สักครั้ง → ลูกค้านี้

คำตัดสินผู้เชี่ยวชาญ: ที่ threshold 0.70 ระบบนี้ "ปลอดภัยเกินไป จนใช้งานไม่ได้"

6. เมตริก ลึก

ขอให้เลิกท่องสูตร แล้วเข้าใจว่าแต่ละเมตริกถูกคิดมาเพื่อตอบคำถามอะไร

Accuracy — เมตริกที่หลอกตา

คำถามที่ตอบ: ทายถูกกี่ %

เมื่อไหร่ใช้ได้: เมื่อ class balanced (50/50) และทุก error เท่าเทียมกัน

เมื่อไหร่หลอก:

ตัวอย่าง: ระบบตรวจมะเร็ง — 99% ของคนไม่เป็นมะเร็ง โมเดลโง่ที่ตอบ "ไม่เป็น" ทุกครั้ง → Accuracy = 99% แต่ **ตรวจคนเป็นมะเร็งไม่เจอเลย** → ใช้ไม่ได้!

ในงานลายนิ้วมือ ถ้าระบบจริงมี impostor 1000 ครั้ง ต่อ genuine 1 ครั้ง → Accuracy จะดูดีหลอก ๆ

Precision — "ฉันมั่นใจแค่ไหน ตอนที่บอกว่าใช่"

คำถามที่ตอบ: ตอนโมเดลตอบ "ใช่" 100 ครั้ง จะถูกจริงกี่ครั้ง

สำคัญเมื่อ: การตอบใช่ผิดมีผลร้ายแรง (security)

V4: 99.88% → โมเดลแทบไม่เคยตอบใช่ผิด

Recall — "ฉันจับเจ้าของจริงได้กี่ %"

คำถามที่ตอบ: จากคู่ genuine 100 คู่ จับได้กี่คู่

สำคัญเมื่อ: การปฏิเสธเจ้าของจริงเป็นเรื่องใหญ่ (usability)

V4: 81.87% → พลาดเจ้าของ 18% (มากเกินไป)

Precision กับ Recall มันคนละมุมกันเสมอ

มุมของระบบ :

Precision สูง = ไม่ค่อยพลาด FP	← "ตอนตอบใช่ มั่นใจ" (ลด FP)
-----------------------------------	---------------------------------

Recall สูง = ไม่ค่อยพลาด FN	← "ไม่ปล่อยให้พลาดเจ้าของ" (ลด FN)
--------------------------------	---------------------------------------

↑ ทั้ง 2 อันมัก trade-off กัน ↑

F1 — เมื่อต้องการตัวเลขสมดุล

F1 คือ **harmonic mean** ของ Precision กับ Recall

ทำไมไม่ใช่ค่าเฉลี่ยปกติ? เพราะถ้าตัวใดตัวหนึ่งเป็น 0, $F1$ ก็ = 0 — มันลงโทษโมเดลที่เก่งด้านเดียว

FAR กับ FRR — ภาษาของ biometric

$FAR = FPR$ (False Positive Rate) $FRR = FNR$ (False Negative Rate)

ทำไมต้องมีชื่อ 2 ชุด เพราะวงการ ML ใช้ FPR/FNR แต่วงการ biometric ใช้ FAR/FRR (และอีกแบบเรียก $FMR/FNMR$)
ความหมายเหมือนกัน 100%

คำถามที่แต่ละตัวตอบ:

Metric	ถามอะไร	ภัยอะไร
FAR	"ในบรรดา impostor ทั้งหมด หลุดมากี่ %"	คนแปลกหน้าเข้าระบบ
FRR	"ในบรรดา genuine ทั้งหมด ถูกปฏิเสธกี่ %"	เจ้าของร้านค้าถูก

EER — ตัวเลขเดียวที่นักวิจัย biometric ดู

$EER = \text{จุดที่ } FAR = FRR$

ทำไมสำคัญ? เพราะมันเป็น **single number** ที่บอกความสามารถโมเดลโดยรวม โดยไม่ต้องเลือก threshold

ตีความ: - $EER 0.05\%$ → ระดับ NIST top-tier - $EER 1\%$ → ระดับ commercial ดี - $EER 5\%$ → พอใช้ - $EER 10\%+$ → ไม่ควรใช้งานจริง

V4: $EER = 4.13\%$ → ระดับ "พอใช้ค่อนข้างดี" ในงานจริง

AUC — ความสามารถแยกแยะ ในมุมมองน่าจะเป็น

ตีความที่คนไม่ค่อยรู้:

$AUC = \text{ความน่าจะเป็นที่ ถ้าสุ่มคู่ genuine 1 คู่ และ impostor 1 คู่ → โมเดลให้ score genuine สูงกว่า impostor}$

- $AUC = 1.0$ → ทำได้ 100% เสมอ
- $AUC = 0.5$ → ทำได้แค่ 50% (เท่าโยนเหรียญ)
- $AUC = 0.99$ → 99 ใน 100 คู่ที่สุ่มมา genuine score > impostor score

V4: 0.9927 → ดีมาก แต่...

⚠ **AUC หลอกได้** ถ้าเลข AUC อยู่ใน 0.99+ ตัวเลขมัน "อึม" — ตรงนี้ EER บอกข้อมูลที่ละเอียดกว่า

d-prime — มุมมองเชิงสถิติ

d-prime = ระยะห่างของ 2 distributions ในหน่วย standard deviation

ถ้า $d' = 3$ → mean ของ genuine อยู่ห่างจาก mean impostor 3 std → distribution เกือบไม่เหลื่อม ถ้า $d' = 1$ → เหลื่อม เยอะ ถ้า $d' = 0$ → ทับกันสนิท (แย่สุด)


V4: $d' = 3.27$ → "ดี" แต่ไม่ "ยอดเยี่ยม"

7. ROC ลึก

ROC คืออะไรจริง ๆ

ROC ไม่ใช่ "กราฟวัดโมเดล" — มันคือ **กราฟที่แสดงทุก threshold พร้อมกัน**

ลองคิดแบบนี้: ถ้าเราเลือก threshold ไหนก็ได้ → ได้ (FAR, TPR) คู่หนึ่ง ROC = ลากเส้นต่อกันของ (FAR, TPR) ทุก threshold ที่เป็นไปได้



วิธี "อ่าน" ROC แบบผู้เชี่ยวชาญ

1. ดูรูปทรงโค้ง

- โค้งติดมุมซ้ายบน → โมเดลดี
- โค้งติดเส้นทแยง → โมเดลห่วย
- โค้งใต้เส้นทแยง → โมเดลกลับหัว (ใช้ 1-score แทน)

2. ดู AUC

- 1.0 = perfect
- 0.99+ = ดีเยี่ยม (แต่ตรวจหา leakage)
- 0.9-0.99 = ดี
- 0.8-0.9 = พอใช้
- <0.8 = แย่

3. ดู "เข่า" ของโค้ง

จุดที่โค้งหักมุมแรงสุด = operating point ที่ดี

4. ดูจุดมุมเล็ก ๆ (FAR ต่ำ)

โซน FAR < 0.01 มักสำคัญที่สุดในงาน biometric

ข้อจำกัดของ ROC

⚠ **ROC ดูเหมือนกันถ้าโมเดลดีมาก** — โมเดล AUC 0.99 และ AUC 0.999 ดูแทบเหมือนกันด้วยตา นี่คือเหตุผลที่ต้องมี DET curve

8. DET, PR ลึก

DET — เห็นความแตกต่างที่ ROC ช่อน

DET = ROC ที่เปลี่ยน: 1. แกน Y เป็น FRR แทน TPR 2. ทั้ง 2 แกนเป็น scale log (probit)

ทำไม? เพราะในงาน biometric เราสนใจ FAR ระดับ 0.01% — ใน ROC จุดพวกนี้อัดที่มุมเดียวกัน DET ขยายโซนนั้นให้เห็นชัด

วิธีอ่าน: - โค้งใกล้ มุมซ้ายล่าง = ดี (FAR ต่ำ + FRR ต่ำ) - เปรียบเทียบโมเดล 2 ตัว = ดูว่าเส้นไหนอยู่ "ใกล้มุมล่างซ้ายมากกว่า"

DET เป็น **มาตรฐานในเปเปอร์ biometric** — ถ้าคุณ submit งานวิจัย ต้องมีกราฟนี้

PR — เมื่อ class imbalance เยอะ

ROC มีจุดอ่อน: ถ้า impostor เยอะกว่า genuine 1000 เท่า — แม้โมเดลให้ FP เยอะ AUC ก็ยังดูดี

PR curve ใช้ Precision แทน FAR → **โดน penaltyหนักเมื่อมี FP**

ใช้ PR เมื่อ: - Genuine มีน้อยมาก - การพลาด FP สำคัญมาก - งาน retrieval/search

ในงานคุณ class balance ~50/50 → ROC, PR ให้ภาพคล้ายกัน แต่ใส่ทั้ง 2 ในรายงานเป็น best practice

9. วิเคราะห์ V4

ตอนนี้มาดูเลขจริงของคุณแบบไม่อัปเดต

ตัวเลขที่ดี

Metric	V4	สถานะ
AUC	0.9927	ดีมาก
AUC-PR	0.9937	ดีมาก
Precision	99.88%	ยอดเยี่ยม
FAR	0.10%	ดีมาก
d-prime	3.27	ดี

ตัวเลขที่น่าเป็นห่วง

Metric	V4	ปัญหา
FRR @ 0.70	18.13%	สูงเกินไปสำหรับ usability
Recall	81.87%	พลาด genuine 18%
EER threshold	0.0000	น่าสงสัยมาก
Min genuine score	0.0000	น่าสงสัยมาก
Max impostor score	0.9999	น่าสงสัยมาก
Separation gap	-0.9999	distributions เหลื่อมสุดขั้ว

🔍 เรื่องที่ซ่อนอยู่ในตัวเลข

ปัญหา 1: EER threshold = 0.0000

ปกติ EER threshold ควรอยู่ใกล้กลาง (0.3-0.7) — ของคุณ = 0 **แปลว่า:** distribution มีรูปร่างผิดปกติ — impostor อัปเดตที่ 0, genuine กระจายตั้งแต่ 0-1 threshold เกือบไม่มีผลต่อ FAR เพราะ impostor "ตาย" ที่ 0 หมดแล้ว

ปัญหา 2: Separation gap = -0.9999

ปกติเราอยากให้ $\min(\text{genuine}) > \max(\text{impostor}) \rightarrow \text{gap} > 0$ ของคุณ $\min(\text{genuine}) = 0$ และ $\max(\text{impostor}) = 0.9999$

แปลว่า: - มี genuine บางคู่ที่โมเดลตอบ 0.0 (มั่นใจว่าไม่ใช่ ทั้งที่จริงคือใช่) ← **catastrophic miss** - มี impostor บางคู่ที่โมเดลตอบ 0.9999 (มั่นใจว่าใช่ ทั้งที่จริงคือไม่ใช่) ← **catastrophic false alarm**

ไม่ใช่ edge case — มันคือความผิดพลาดร้ายแรง

ปัญหา 3: Score มี bimodal สุดขั้ว

- Median genuine = 1.000 (ครึ่งหนึ่งของ genuine คะแนน = 1 เป๊ะ)
- Median impostor = 0.000 (ครึ่งหนึ่งของ impostor คะแนน = 0 เป๊ะ)

นี่คือสัญญาณว่าโมเดล **"overconfident"** — มันไม่ให้ความน่าจะเป็นแบบมีระดับ มันตอบ all-or-nothing ผลกระทบ: threshold tuning ทำได้ยาก เพราะไม่มีค่ากลาง

สรุปประเมิน V4

คะแนนรวม: **B+** (ดี แต่ไม่ดีพอสำหรับ production)

จุดแข็ง: - ☒ Security ดี (FAR ต่ำ) - ☒ แยก distribution หลักได้ดี (AUC 0.99+) - ☒ จัดการ same-person-different-finger ได้ (0.5% FAR)

จุดอ่อน: - ☒ FRR สูงไป (18% — ผู้ใช้ทนไม่ไหว) - ☒ Bimodal output → calibration แย่ - ☒ มี catastrophic errors (score 0 ที่ควร 1, และ 1 ที่ควร 0) - ☒ ทำ FAR < 0.01% ไม่ได้ — ใช้งาน high security ไม่ได้

10. Red Flags

ในฐานะผู้เชี่ยวชาญ ขอแนะนำสัญญาณที่ "ดูดี" แต่จริง ๆ มีปัญหา

▶ Red Flag 1: AUC = 1.0000

ปกติไม่เกิดขึ้น — ถ้าได้ ให้สงสัย: - Data leakage (test set โผล่ใน train) - คน/นิ้วเดียวกันกระจายอยู่ทั้ง train+test - Bug ในการคำนวณ

V3 ของคุณได้ AUC = 1.0000 → **น่าจะมี leakage** จริง ๆ ตามที่ data_leakage_audit.md ระบุ

▶ Red Flag 2: EER threshold ที่สุดขั้ว (0 หรือ 1)

ปกติควรอยู่กลาง — ถ้าใกล้ 0 หรือ 1 แปลว่า distribution มีรูปร่างแปลก

▶ Red Flag 3: Min(genuine) = 0 หรือ Max(impostor) = 1

แปลว่ามีคู่ที่โมเดลตอบ **ผิดแบบมั่นใจสุดขีด** — ไม่ใช่การ "เกือบจะถูก" แต่ "ผิดแบบตื้อ ๆ"

ปกติ: - Min(genuine) ควร > 0.3 - Max(impostor) ควร < 0.7

ถ้าไม่ใช่ → ต้องไปดูภาพคู่ที่ผิด มันมีอะไรพิเศษ

▶ Red Flag 4: FAR หรือ FRR คงที่ทุก threshold

หมายความว่า distribution อัดอยู่ขั้วเดียว — threshold tuning ไม่ได้ผล V4 ของคุณ FAR คงที่ที่ 0.10% ทุก threshold → bimodal โมเดลอัด impostor ที่ 0 หหมด

▶ Red Flag 5: Score distribution เป็น bimodal สุดขั้ว

โมเดลที่ดีควรให้ probability ที่ "smooth" — ไม่ใช่ตอบ 0 หรือ 1 อย่างเดียว

วิธีแก้: - Temperature scaling (calibration) - Train ด้วย label smoothing - ใช้ margin-based loss แทน BCE

▶ Red Flag 6: AUC ดีมาก แต่ accuracy ที่ threshold default ห่วย

แปลว่า threshold default ไม่เหมาะกับโมเดลนี้ — ต้อง tune

11. คำแนะนำ

ในฐานะผู้เชี่ยวชาญ ถ้าคุณจะนำเสนอ V4 ในงาน

ในรายงาน ต้องมี

1. **Score distribution plot** — ให้เห็นว่า 2 กลุ่มแยกกันแค่ไหน (พื้นฐานที่สุด)
2. **ROC + AUC** — มาตรฐาน
3. **DET curve** — เฉพาะงาน biometric
4. **EER + EER threshold** — single number ที่ใช้เทียบ
5. **FNMR @ Fixed FMR table** — operating point มาตรฐานอุตสาหกรรม
6. **Confusion matrix ที่ optimal threshold** (ไม่ใช่ 0.70)
7. **Threshold sweep** — บอกว่า threshold ต่าง ๆ ให้ผลยังไง

ในการพูด ต้องอธิบาย

- ระบบนี้คือ **verification (1-to-1)** ไม่ใช่ identification
- output เป็น **score** ไม่ใช่ class
- เลือก threshold ตาม **use case** ไม่ใช่ default 0.5
- **EER** เป็นตัวชี้วัดหลัก ไม่ใช่ Accuracy

สิ่งที่ V4 ควรปรับปรุง

1. **ลด threshold default จาก 0.70 → ~0.05** (Youden's J) — ได้ F1 0.96+ แทน 0.90
2. **Calibrate score distribution** ด้วย temperature scaling หรือ Platt scaling
3. **Investigate catastrophic errors** — คู่ที่ score 0 แต่เป็น genuine, และ score ≈ 1 แต่เป็น impostor
4. **Train V5** ด้วย label smoothing เพื่อลด overconfidence

คำสุดท้าย

โมเดลที่ดีไม่ใช่โมเดล Accuracy 99% โมเดลที่ดีคือโมเดลที่: - คุณ **เข้าใจว่ามันทำงานอย่างไร** - คุณ **รู้ว่ามันพลาดที่ไหน**
- คุณ **เลือก operating point ตาม use case ได้** - คุณ **สื่อสารกับ stakeholder ได้**

ตัวเลขเป็นเครื่องมือ — ความเข้าใจคือเป้าหมาย

ภาคผนวก: Checklist ก่อนนำเสนอ

- [] รู้ว่าโมเดลรับ input อะไร ส่ง output อะไร
 - [] อ่าน score distribution ออก
 - [] อธิบาย confusion matrix ได้ 4 ช่อง
 - [] รู้ว่า FAR, FRR, FMR, FNMR คือสิ่งเดียวกัน
 - [] อ่าน ROC + DET ออก
 - [] รู้ว่า threshold default ไม่ใช่ best
 - [] เลือก operating point ตาม use case ได้
 - [] เห็น red flag ในผลของตัวเอง
 - [] อธิบายข้อจำกัดได้
-

เอกสารฉบับนี้เขียนสำหรับโปรเจกต์ Fingerprint Matching V4